

Metody rozpoznawania obrazów i podstawy uczenia maszynowego

Zadanie 1

Wykonanie: Kamil Kurp

Zadanie A


Liczba powtórzeń dla każdego wymiaru: 500

Liczba wygenerowanych punktów: 300

Tabela wyników:

dimension	sphere_filled	error
1	100	0
2	78,48	1,84
3	52,24	2,23
4	30,82	2,09
5	16,33	1,62
6	8,04	1,15
7	3,73	0,86
8	1,60	0,52
9	0,68	0,35
10	0,26	0,21
11	0,09	0,13
12	0,031	0,081
13	0,013	0,049
14	0,004	0,028
15	0,001	0,016

Wykres średnich wyników dla każdego wymiaru (na czerwono) z error bars (na niebiesko):



Zadanie B


Liczba powtórzeń dla każdego wymiaru: 120

Liczba wygenerowanych punktów: 70

Tabela wyników:

dimension	stddev/mean	error
1	0,7038	0,0072
2	0,473	0,0069
3	0,3744	0,0067
4	0,3192	0,0064
5	0,2816	0,0069
6	0,2528	0,0058
7	0,2331	0,0058
8	0,2175	0,0054
9	0,2031	0,0047
10	0,193	0,0049
11	0,1828	0,0045
12	0,1751	0,0044
13	0,1677	0,0042
14	0,1611	0,0039
15	0,1556	0,0041

Wykres średnich wyników dla każdego wymiaru (na czerwono) z error bars (na niebiesko):



Podsumowanie:

Klątwa wymiarów to problem który pojawia się przy analizowaniu i organizowaniu danych w wielowymiarowych przestrzeniach. Występuje on w wielu dziedzinach, takich jak kombinatoryka, uczenie maszynowe czy analiza numeryczna, między innymi problem także ma wpływ na algorytmy rozpoznawania wzorców. Jak można zauważyć na wykresach, dodając nowe wymiary powodujemy, że trudniej jest nam losowo trafić w punkt, który znajduje się w kuli. Powodem jest to, że każdy nowy wymiar mnoży nam cały zakres możliwych do wystąpienia wartości. Jeśli chcemy osiągnąć miarodajne rezultaty eksperymentu statystycznego, to im więcej jest wymiarów, tym wykładniczo rośnie liczba potrzebnych danych wejściowych. Jest to też powodem, dla którego warto stosować metody pozwalające na redukcję wymiarowości.