

Metody rozpoznawania obrazów i podstawy uczenia maszynowego

Zadanie: Metric Learning

Wykonanie: Kamil Kurp

Zbiór wejściowy - bitmapa:




Klasa A – kolor czerwony

Klasa B – kolor zielony


Klasa C – kolor niebieski

1. Zwykły k-NN z $k=1$ i metryką Euklidesa




Błąd: 26.08%

2. Zwykły k-NN z $k=3$ i metryką Euklidesa




Błąd: 19.87%

3. Zwykły k-NN z $k=1$ i metryką Mahalanobisa




Błąd: 24.22%

4. Zwykły k-NN z $k=1$ i metryką wyuczoną uprzednio z użyciem algorytmu Large Margin Nearest Neighbor




Błąd: 24.84%

Drugi zbiór wejściowy:




1. Zwykły k-NN z $k=1$ i metryką Euklidesa




Błąd: 21.96%

2. Zwykły k-NN z $k=3$ i metryką Euklidesa




Błąd: 21.96%

3. Zwykły k-NN z $k=1$ i metryką Mahalanobisa



Błąd: 20.80%

4. Zwykły k-NN z $k=1$ i metryką wyuczoną uprzednio z użyciem algorytmu Large Margin Nearest Neighbor



Błąd: 20.80%

Podsumowanie:

Dla metryki Euklidesa i $k = 1$ wystarczył jeden punkt danego koloru aby powstała „wyspa”. Granica decyzyjna jest wyrazista, pełna kątów prostych. Błąd dla tego klasyfikatora wydają się być większy niż dla pozostałych, co wskazuje, że $k = 1$ nie jest optymalną wartością parametru. Gdy zmienimy k na 3, to zauważamy, że zanikają wyspy składające się z małej ilości bliskich obserwacji, a granice decyzyjne są wygładzone. Błąd dla takiej wartości k jest mniejszy, więc taki klasyfikator jest bardziej użyteczny. Dla metryki Mahalanobisa granica decyzyjna jest odrobinę łagodniejsza niż w w euklidesowej, błąd też jest nieco mniejszy. Zmiana stosowanej metryki na wyuczoną za pomocą LMNN spowodowała przekrzywienie płaszczyzny razem z punktami, zgodnie z tym, jak układały się klasy punktów. Pierwszy zbiór wejściowy został lepiej sklasyfikowany, prawdopodobnie ze względu na mniejszą ilość szumu niż w zbiorze drugim.